logcomex.ai × databricks

Workshop hands-on: do dado bruto ao produto de dados

Engenharia de dados · AI/BI Dashboards · Genie · Databricks Apps — aplicados ao comércio exterior

Roteiro do instrutor
Escritório LogComex · 13:00 – 17:00
Público: time técnico de dados (engenharia, analytics, ciência de dados)

1 Visão geral

Objetivo

Mostrar, na prática e em uma tarde, como o time de dados da LogComex pode sair de **arquivos brutos de comércio exterior** (DIs, DU-Es, eventos de rastreamento de armadores) e chegar a **produtos de dados prontos para o cliente final** — um dashboard governado, uma interface de perguntas em linguagem natural e uma aplicação web — **tudo em uma única plataforma**, com governança do Unity Catalog do início ao fim.

> **Ao final, cada participante terá construído no próprio ambiente:**
> ① um pipeline medalhão (Bronze → Silver → Gold) com ingestão incremental · ② o dashboard AI/BI **Radar Comex** · ③ um Genie space em português sobre comex · ④ o app **Radar Comex** (Streamlit) publicado, com chat integrado ao Genie.

Formato e premissas

- **Hands-on individual:** cada participante executa os notebooks no seu ambiente. Todo o setup é automatizado (notebook `00_Setup`, ~3 min).
- **Isolamento:** cada pessoa ganha um schema próprio `logcomex_ws_<usuario>`, um dashboard, um Genie space e um app com o seu nome — funciona tanto em workspaces individuais quanto em um workspace compartilhado.
- **Dados 100% sintéticos**, mas realistas: NCMs reais, portos/URFs, canais de parametrização, armadores, PTAX. Nenhum dado de cliente.
- **Engenharia de dados no nível essencial** (30 min): o foco da tarde está em consumo — Dashboards, Genie e Apps.

A história escondida nos dados

Os dados foram gerados com três "achados" para os participantes descobrirem com cada ferramenta — use-os para dar ritmo e gerar o efeito "uau" ao longo da tarde:

Achado	O que aparece nos dados	Onde é descoberto
⚡ **Boom dos veículos elétricos**	Importação da NCM 8703.80.00 (majoritariamente da China) cresce forte a partir de 2025: US$ 577,7 mi em 2024 → US$ 3,0 bi em 2025 → US$ 4,7 bi só até set/2026.	Dashboard (filtro Automotivo), Genie, App (aba NCM)
🚧 **Gargalo em Paranaguá**	Desde jun/2026 o tempo médio de desembaraço marítimo em Paranaguá sobe de 2,3 para 5,9 dias, com mais DIs em canal vermelho (6% → 13%).	Lab 1 (1ª descoberta), Dashboard pág. 2, Genie
🦕 **Armador com atrasos crescentes**	ZIM tem o maior atraso médio vs. ETA (5,5 dias, contra 2,0 dias da média dos demais), concentrado nas rotas da Ásia.	Dashboard pág. 2, Genie, App (Rastreamento)

Materiais do workshop

Arquivo	Uso
`LogComex_Workshop.dbc`	Pacote com todos os notebooks — o participante importa no workspace (Workspace → Import).
`00_Setup`	Lab 0 · cria schema, volume, dados sintéticos, escolhe o warehouse e já cria o app (compute sobe em background). Tem modo *fast-track*.
`01_Engenharia_de_Dados`	Lab 1 · Auto Loader, `read_files`, Silver com qualidade/quarentena/constraint, Gold, comentários, time travel, linhagem.
`02_Dashboard_AIBI`	Lab 2 · cria e publica o dashboard Radar Comex via API + exercícios guiados.
`03_Genie`	Lab 3 · cria o Genie space curado (instruções, exemplos SQL, perguntas sugeridas, benchmarks) + exercícios.
`04_Databricks_Apps`	Lab 4 · gera o código do app, aplica permissões mínimas ao service principal, faz deploy + exercícios.
`05_Demo_Instrutor_App_React`	Demo do instrutor (opcional) · publica o mesmo Radar Comex em React + FastAPI para o fechamento do Lab 4.
`00_Instrutor_Preparacao` · `99_Limpeza`	Preparação de workspace compartilhado (instrutor) · remoção dos recursos de cada participante.

2 Agenda minuto a minuto

Horário	Bloco	O que acontece
13:00 – 13:30	**Chegada**	Recepção, Wi-Fi, login no workspace, importação do `.dbc`. **Peça para cada um já rodar o `00_Setup`** (ganha-se ~10 min de workshop e o compute dos apps sobe com folga).
13:30 – 13:35	Abertura	Boas-vindas, objetivos, agenda, regras do hands-on (ajudantes circulando, canal de dúvidas).
13:35 – 13:47	Teoria 1	Data Intelligence Platform e Lakehouse: por que uma plataforma única para dados + IA.
13:47 – 13:57	Teoria 2	Unity Catalog: governança, linhagem, compartilhamento — essencial para dados de clientes da LogComex.
13:57 – 14:07	Teoria 3	Lakeflow (Connect, Declarative Pipelines, Jobs) e Delta Lake — engenharia de dados no Databricks.
14:07 – 14:15	Teoria 4	Databricks SQL e AI/BI Dashboards.
14:15 – 14:22	Teoria 5	AI/BI Genie: perguntas em linguagem natural com semântica curada.
14:22 – 14:30	Teoria 6	Databricks Apps + como tudo se conecta para a LogComex · perguntas.
14:30 – 14:40	**Lab 0**	Checagem do setup (quem não rodou, roda agora; quem teve problema usa *fast-track*).
14:40 – 15:10	**Lab 1**	Engenharia de dados: Bronze → Silver → Gold.
15:10 – 15:40	**Lab 2**	AI/BI Dashboards.
15:40 – 15:50	☕ Intervalo	Use para destravar quem estiver atrasado (fast-track do Lab 1).
15:50 – 16:20	**Lab 3**	Genie.
16:20 – 16:45	**Lab 4**	Databricks Apps.
16:45 – 17:00	**Encerramento**	Recapitulação, mapa de casos de uso LogComex, próximos passos, pesquisa de satisfação.

> **Regra de ouro do tempo:** cada lab tem um **núcleo obrigatório** (primeira metade do tempo) e **exercícios de aprofundamento**. Se a turma atrasar, faça só o núcleo e siga — o modo *fast-track* e a criação automática de dashboard/Genie/app garantem que ninguém fica sem os artefatos do lab seguinte.

Lab	Núcleo obrigatório	Pode cortar se atrasar
Lab 1	1.1 a 1.5 (Run das células + leitura guiada)	1.6 governança (mostre só a linhagem na tela)
Lab 2	Criar + explorar + 1 visualização com IA	Dataset SQL próprio, agendamento
Lab 3	Criar + perguntas + ensinar "operação crítica"	SQL expressions, benchmarks
Lab 4	Deploy + explorar + 1 alteração e redeploy	Desafio com Assistant, permissões

3 Preparação

Escolha da modalidade de ambiente

A Workspace próprio por participante
Cada participante usa o seu workspace (com Unity Catalog). Nada a preparar além dos pré-requisitos abaixo — os notebooks detectam o catálogo padrão automaticamente (widget `catalogo` permite trocar).

B Workspace compartilhado
Todos no mesmo workspace (ex.: `fevm-serverless-stable-g01yyz`). Adicione os participantes como usuários e rode **uma vez** o notebook `00_Instrutor_Preparacao` (concede `USE CATALOG` / `CREATE SCHEMA` e `CAN_USE` no warehouse). Cada pessoa continua isolada no próprio schema/app.

Pré-requisitos do workspace

Recurso	Por quê
Unity Catalog + catálogo com `CREATE SCHEMA`	Cada participante cria o schema `logcomex_ws_<usuario>`.
Compute **serverless** para notebooks	Todos os labs rodam em serverless (sem cluster para configurar).
SQL Warehouse (serverless de preferência)	Dashboard, Genie e App. O setup reaproveita um existente ou cria um 2X-Small.
AI/BI Genie, Dashboards e Databricks Assistant	Labs 2 e 3; Assistant usado nos desafios dos Labs 1, 2 e 4.
Databricks Apps habilitado + cota de apps	1 app por participante. Verifique o limite de apps do workspace para o tamanho da turma.

Checklist

D-7

☐ Confirmar modalidade (A ou B) e lista de participantes/e-mails.
☐ Validar pré-requisitos e cota de apps.
☐ Se modalidade B: criar usuários e rodar `00_Instrutor_Preparacao`.
☐ Enviar aos participantes: link do workspace + `LogComex_Workshop.dbc`.
☐ Preparar os slides da parte teórica (estrutura na seção 4).

D-1

☐ Rodar o fluxo completo com um usuário de teste (Setup → Lab 4, ~15 min) e o `05_Demo_Instrutor_App_React` com o seu.
☐ Verificar a validade do workspace (FEVM: estender se necessário).

Dia — 12:30

☐ Testar projetor/Wi-Fi e login no workspace pela rede do cliente.
☐ Ligar o SQL Warehouse (evita a espera de partida a frio).
☐ Deixar abertas no seu navegador: seu dashboard, Genie, app Streamlit e app React já prontos (plano B e demo final).

Durante a chegada (13:00–13:30)

☐ Workspace → sua pasta → **Import** → arquivo `.dbc`.
☐ Abrir `00_Setup` → compute **Serverless** → **Run all**.

4 Introdução e apresentação teórica

13:30 – 14:30 · 60 min

Sugestão: ~25 slides, poucos textos e uma demonstração rápida ao vivo no final de cada bloco (≤ 1 min). Sempre ancore os conceitos no dia a dia da LogComex: **dados de comércio exterior em escala, de muitas fontes, servidos a clientes** por meio de produtos com IA.

Abertura — 5 min

- Objetivo da tarde e o que cada um levará pronto (os 4 artefatos).
- Agenda e dinâmica: "teoria curta, mão na massa longa". Quem tiver dúvida levanta a mão — há ajudantes circulando.

1 · Data Intelligence Platform — 12 min

- Lakehouse: dados em formato aberto (Delta Lake / Apache Iceberg) no seu storage + um único motor para engenharia, BI, ciência de dados e IA generativa.
- "Inteligência de dados": a plataforma entende a semântica do *seu* negócio (metadados, uso, linhagem) — base do Assistant, do Genie e dos dashboards com IA.
- Serverless: sem clusters para dimensionar; paga-se pelo uso.

> *"Hoje uma DI nasce num arquivo do Siscomex e termina como um insight no produto de vocês. Quantas ferramentas existem nesse caminho? A proposta é que seja uma só."*

2 · Unity Catalog — 10 min

- Hierarquia `catálogo.schema.objeto` para tabelas, volumes (arquivos), funções, modelos, dashboards e Genie.
- Permissões em SQL (`GRANT`), linhagem automática até a coluna, auditoria, tags e classificação de dados sensíveis (ex.: CNPJ).
- Filtros de linha e máscaras de coluna → cada cliente da LogComex enxerga só os próprios dados no mesmo modelo.
- Delta Sharing: compartilhar dados com clientes e parceiros sem cópia.

3 · Engenharia de dados: Lakeflow + Delta Lake — 10 min

- **Lakeflow Connect** (conectores gerenciados para bancos e SaaS), **Auto Loader** para arquivos, **Declarative Pipelines** (SQL/Python declarativo com qualidade embutida) e **Jobs** (orquestração).
- Arquitetura medalhão: Bronze (como chegou) · Silver (limpo e conformado) · Gold (pronto para o negócio).
- Delta Lake: ACID, *constraints*, histórico, *time travel*, otimizações automáticas (liquid clustering, predictive optimization).

4 · Databricks SQL e AI/BI Dashboards — 8 min

- SQL Warehouse serverless: partida em segundos, alta concorrência — o motor por trás de dashboards, Genie e apps.
- Dashboards nativos sobre o Unity Catalog: sem extrações, permissões herdadas, criação de gráficos por linguagem natural, publicação com credenciais embutidas, agendamentos e **embedding** em portais externos.

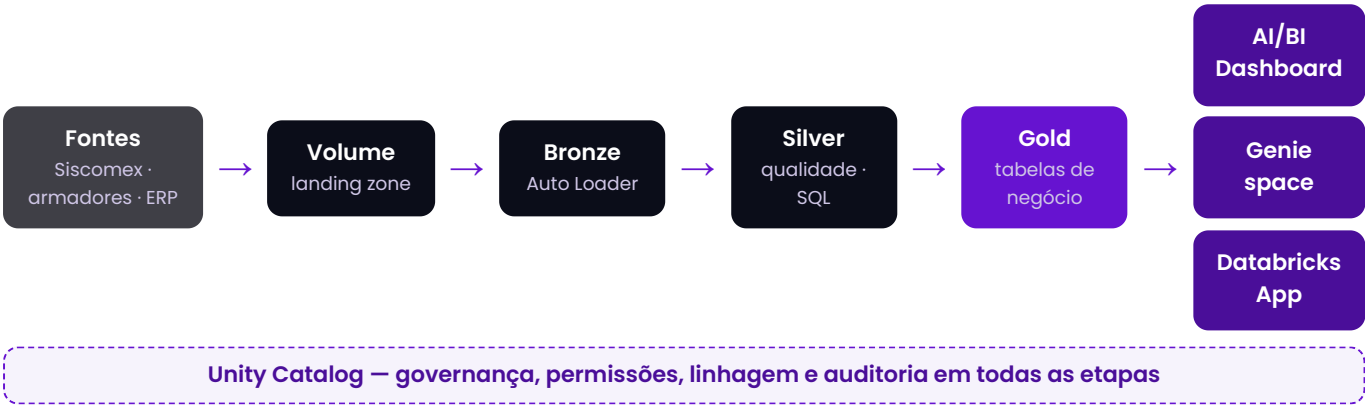
5 · AI/BI Genie — 7 min

- Perguntas em português → SQL auditável → tabela/gráfico. O "segredo" é a **curadoria**: tabelas certas, comentários, instruções de negócio, exemplos de SQL e benchmarks.
- Genie Conversation API: levar a experiência para dentro de aplicações (o que faremos no Lab 4) e de ferramentas como Slack/Teams.

> *"O Genie não é um chatbot genérico: é o time de dados de vocês ensinando o vocabulário do comex — FOB, CIF, canal vermelho, transit time — uma vez, para todos usarem."*

6 · Databricks Apps e a visão integrada — 8 min

- Apps (Streamlit, Dash, Gradio, FastAPI, React…) hospedados na plataforma: SSO, service principal próprio, acesso nativo a SQL, Genie, Model Serving e Lakebase.
- Desenho final da tarde: arquivos → pipeline → Gold → Dashboard + Genie → App. Mostre o diagrama abaixo e abra para perguntas.



5 Condução dos labs

14:30 – 16:45

Lab 0 · Setup automatizado

14:30 – 14:40

Notebook: `00_Setup` · **Execução:** Run all (~3 min).

- Mostre na tela a tabela do topo do notebook: o que é criado e onde. Explique o isolamento por usuário.
- Mostre a mensagem final ✅ **Ambiente pronto** com os volumes gerados (47.040 DIs, 20.077 DU-Es, 33.202 eventos).
- Abra o Volume no **Catalog Explorer** e mostre as pastas da landing zone.

> **Se algo falhar:** confira se o notebook está em **Serverless** e se o catálogo do widget tem permissão de `CREATE SCHEMA`. Quem estiver muito atrasado: widget `fast_track = sim` e rodar a célula 5 — executa o Lab 1 inteiro.

Lab 1 · Engenharia de dados

14:40 – 15:10

Notebook: `01_Engenharia_de_Dados` · **Dinâmica:** célula a célula, o instrutor projeta e comenta; a turma acompanha.

Passo	O que destacar	Resultado esperado
1.1 Landing	`read_files` lê CSV direto em SQL, com schema inferido.	10 DIs de ago/2026.
1.2 Bronze	Auto Loader com `availableNow`: checkpoint, incremental, metadados de auditoria. JSON aninhado com `read_files`.	45.274 linhas em `bronze_importacoes`.
1.3 Arquivo novo	Chega o CSV de set/2026: só ele é processado — sem reprocessar 32 meses.	+1.766 linhas novas.
1.4 Silver	Diagnóstico de qualidade → tipagem, padronização de países, dedupe com `QUALIFY`, enriquecimento (NCM, empresa, PTAX), quarentena e `CHECK constraint`.	46.295 DIs válidas · 279 em quarentena · grafias de países: 77 → 26.
1.5 Gold	3 tabelas de negócio: balança mensal, desempenho de portos, situação de cada contêiner.	1ª descoberta: **Paranaguá** 2,3 → 5,9 dias.
1.6 Governança	Comentários de colunas (alimentam o Genie!), tags, `DESCRIBE HISTORY`, time travel e grafo de linhagem.	Linhagem arquivo → bronze → silver → gold.

> *"Repare que não configuramos nada para ter linhagem, histórico ou auditoria — isso vem do Unity Catalog e do Delta. Em produção, este mesmo SQL vira um Lakeflow Declarative Pipeline ou um Job agendado."*

Perguntas para a turma: Onde hoje vocês tratam duplicidade de DIs? Como garantem que um valor FOB negativo não chegue ao cliente?

Lab 2 · AI/BI Dashboards

15:10 – 15:40

Notebook: `02_Dashboard_AIBI` · a 1ª célula cria e publica o dashboard **Radar Comex** (2 páginas + filtros globais, tema roxo/preto LogComex).

1. **Explorar (5 min)** — clique em *China* no gráfico de países (cross-filter); filtre *Automotivo* e mostre o salto de 2025; na página 2, Paranaguá em roxo no gráfico de desembaraço e o ranking de armadores.
2. **Visualização com IA (10 min)** — Edit draft → Add a visualization → ✨ *"Gráfico de barras com as 10 NCMs com maior valor FOB importado"*. Mostre a edição do gráfico gerado.
3. **Dataset SQL (5 min)** — preço médio US$/kg por NCM e país: o clássico de inteligência de mercado da LogComex.
4. **Publicar e distribuir (5 min)** — credenciais embutidas × do visualizador, Share, Schedule por e-mail.

> **Valores de referência (filtro padrão, todo o período):** FOB importado ≈ US$ 51,9 bi · FOB exportado ≈ US$ 148,8 bi · saldo ≈ US$ 96,9 bi · 66.213 operações. Tempo médio de desembaraço geral ≈ 2,2 dias; canal vermelho ≈ 6,1%.

> *"Esse mesmo dashboard pode ser embarcado no portal de um cliente da LogComex, com filtro por linha garantindo que cada cliente veja só os próprios processos."*

Lab 3 · Genie

15:50 – 16:20

Notebook: `03_Genie` · a 1ª célula cria o espaço curado (7 tabelas, glossário de comex, 3 exemplos SQL, 6 perguntas sugeridas, 3 benchmarks).

1. **Perguntas (8 min)** — sugeridas + livres. Peça para sempre abrir **Show code**. Sugestão ao vivo: *"Compare o tempo de desembaraço de Paranaguá com Santos nos últimos 6 meses"* → *"mostre em um gráfico de linhas"* → *"por que aumentou?"*.
2. **Ensinar um conceito (10 min)** — *"Quantas operações críticas tivemos em 2026?"* antes e depois da instrução *"Operação crítica = DI em canal Vermelho ou Cinza com valor FOB acima de US$ 1 milhão"*. Resultado esperado após a instrução: **185** DIs.
3. **Benchmarks (5 min)** — Run all benchmarks; discuta como isso vira um processo de qualidade contínuo.
4. **Distribuição (5 min)** — Genie dentro do dashboard, Share com *Can run*, API (gancho para o Lab 4).

Pergunta	Resposta esperada
Qual armador tem o maior atraso médio nas rotas vindas da Ásia?	ZIM (≈ 7,0 dias)
Quais os 10 maiores importadores de veículos elétricos em 2026?	Líder: Capixaba Autopeças Importação e Exportação Ltda
Qual o valor FOB total importado em 2025?	≈ US$ 19,0 bi

> *"Tudo o que o Genie respondeu passou pelas permissões do Unity Catalog de quem perguntou. Não há um atalho para os dados."*

Lab 4 · Databricks Apps

16:20 – 16:45

Notebook: `04_Databricks_Apps` · o app foi criado no Lab 0, então o compute já está ativo.

1. **4.1 Código** — grava `app.py` (Streamlit) e `app.yaml` (comando + variáveis) na pasta do usuário. Abra o `app.py` no editor e mostre as 4 abas e a função `genie()` (Conversation API em ~30 linhas).
2. **4.2 Permissões** — o service principal do app recebe só `SELECT` no schema, `CAN_USE` no warehouse e `CAN_RUN` no Genie.
3. **4.3 Deploy** (~1–3 min) e exploração: filtros, aba NCM (veículos elétricos × painéis solares), rastreamento de um contêiner atrasado, chat com o Genie.
4. **Alterar e redeployar** — descomentar o bloco `🏁 EXERCÍCIO DO LAB 4` (Top 10 destinos das exportações) e rodar a célula 4.3 de novo.
5. **Desafio** — pedir ao Assistant, no editor do `app.py`, um gráfico de pizza por via de transporte.
6. **Fechamento do instrutor (3 min)** — abra o seu app React (`05_Demo_Instrutor_App_React`) ao lado do Streamlit: mesmos dados, mesmo SSO e permissões, agora como produto (React + API FastAPI). Mostre a troca de filtros sem recarregar a página e o chat com o Genie.

> *"Esse é o caminho mais curto entre o time de dados e um produto: o mesmo dado governado, servido por um app com SSO, sem infraestrutura para manter. O time de dados prototipa em Streamlit; o time de produto entrega em React — na mesma plataforma. Para produção, versionem em Git e implantem com Asset Bundles."*

6 Encerramento

16:45 – 17:00

- **Recapitulação (5 min)** — volte ao diagrama da teoria e marque o que cada um construiu: pipeline, dashboard, Genie, app.
- **Mapa de oportunidades LogComex (5 min)** — pergunte à turma onde aplicariam primeiro. Exemplos para provocar:
  - ingestão incremental das bases de DI/DU-E e de tracking com Lakeflow, com qualidade declarativa;
  - dashboards AI/BI embarcados para clientes, com segurança por linha (cada cliente vê seus processos);
  - Genie como "analista de comex" interno e, via API, dentro dos produtos da LogComex;
  - Apps para protótipos rápidos de novos produtos de dados e ferramentas internas.
- **Próximos passos (5 min)** — definir 1 caso de uso para um piloto com critérios de sucesso, sessão de arquitetura com o time, trilhas gratuitas da Databricks Academy, pesquisa de satisfação.

Mensagem final: em uma tarde, saímos de arquivos brutos de comércio exterior para um produto de dados com BI, IA conversacional e uma aplicação — tudo governado em um só lugar. O próximo passo é fazer isso com os dados reais da LogComex.

7 Solução de problemas

Sintoma	Causa provável → solução
`PERMISSION_DENIED ... CREATE SCHEMA` no Setup	Catálogo sem permissão. Troque o widget `catalogo` por um catálogo onde o usuário pode criar schemas, ou (modalidade B) rode `00_Instrutor_Preparacao`.
Widget `catalogo` mostra `hive_metastore`	Workspace sem catálogo padrão no UC. Informe um catálogo do Unity Catalog no widget.
"Tabelas Gold não encontradas" nos Labs 2–4	Lab 1 incompleto. Rode o `00_Setup` com `fast_track = sim` (célula 5).
Notebook pede para criar cluster	Selecione **Serverless** no seletor de compute.
Dashboard com widgets vazios	Warehouse parado/iniciando: aguarde ~30 s e atualize. Confirme o warehouse em *Data* do dashboard.
Genie responde "não tenho acesso"	O usuário precisa de `SELECT` nas tabelas (ok no próprio schema) e `CAN_USE` no warehouse.
Deploy do app: `TimeoutError` no compute	Compute ainda subindo ou parado — rode a célula 4.3 de novo (ela reinicia o compute automaticamente).
App abre mas mostra erro de permissão em SQL	A célula 4.2 avisou ⚠️ em `USE CATALOG` /warehouse: o instrutor/admin concede (ou rode `00_Instrutor_Preparacao`) e recarregue o app.
App: erro após editar `app.py`	Abra `<url do app>/logz`. Para voltar ao original: widget `recriar_codigo = sim` na célula 4.1.
Limpeza pós-workshop	Notebook `99_Limpeza` (widget `confirmar = sim`) remove app, Genie, dashboard e schema do participante.
Limite de apps do workspace atingido	Participantes formam duplas (um app por dupla) ou removem apps antigos que sejam deles.

8 Apêndice · modelo de dados

Tabela	Conteúdo	Linhas
`silver_importacoes`	1 linha por DI: importador, NCM, país, URF, via, incoterm, FOB/CIF/BRL, II estimado, canal, dias de desembaraço, armador.	46.295
`silver_exportacoes`	1 linha por DU-E: exportador, NCM, país de destino, porto, FOB.	19.918
`silver_eventos_embarque`	Milestones dos contêineres (GATE_IN … GATE_OUT).	32.711
`silver_empresas` · `silver_ncm` · `silver_cambio_diario`	Dimensões: 380 empresas, 37 NCMs, PTAX diária.	—
`gold_comercio_exterior_mensal`	Balança mensal por fluxo, NCM, país, UF, porto e via.	31.175
`gold_desempenho_portos`	DIs, canais e tempo de desembaraço por mês e URF.	462
`gold_embarques`	1 linha por contêiner: rota, ETA, transit time, atraso, status.	5.200